

## TRATAMIENTO DE SOMBRAS EN FOTOGRAFIAS DE DOCUMENTOS

```
# importamos librerias utilizadas
import cv2
import numpy as np
import matplotlib.pyplot as plt
from scipy import ndimage, misc
import matplotlib.pyplot as plt

# definimos una funcion para graficar las imagenes
def imprimir_pic(pic,etiqueta):
    plt.figure()
    plt.imshow(pic, cmap = 'gray')
    plt.title(etiqueta)
    plt.axis('off')

#imagen_entrada = "cejem1"
#input_pic = cv2.imread(imagen_entrada+".png")
#cv2.imwrite(imagen_entrada+".jpeg", input_pic)
```

Seleccionamos la imagen con la cual se va a trabajar

```
imagen_entrada = "input2"
input_pic = cv2.imread(imagen_entrada+".jpeg")
```

## METODO BASE

Generamos la mascara o "perfil de sombra"

```
# Paquetes necesarios para la morfología matemática
from skimage.morphology import erosion, dilation, opening, closing
# Elementos estructurales
from skimage.morphology import disk, diamond, ball, rectangle, star
from scipy import ndimage as ndi
#reducimos la pic a grises
input_pic = cv2.cvtColor(input_pic, cv2.COLOR_BGR2GRAY)

#realizamos una copia de la pic recibida para poder modificarla en un
espacio de memoria diferente
mask = np.copy(input_pic)
#las siguientes 3 líneas se encargan de normalizar la pic de 0 a 255
mask = mask - mask.min()
mask = mask/mask.max()
mask = mask*255
```

*#Creamos la mascara con un filtro de mediana, consideramos las letras como ruido*

```
for i in range(3):  
    mask = ndimage.median_filter(mask, size=18, mode='reflect')
```

```
mask_gris = np.copy(mask)
```

```
imprimir_pic(mask, 'Máscara en grises')
```

*#la maskara debe estar en blanco y negro y no en escala de grises, asi que se realiza un if:*


```
promedio = np.mean(mask)  
for (cor_y, cor_x), value in np.ndenumerate(mask):  
    if mask[cor_y, cor_x] < promedio: #Good Pixel  
        mask[cor_y, cor_x] = 0.1  
    elif mask[cor_y, cor_x] > promedio: #Bad Pixel  
        mask[cor_y, cor_x] = 254.9
```

```
imprimir_pic(mask, 'Máscara')  
imprimir_pic(input_pic, 'original')
```

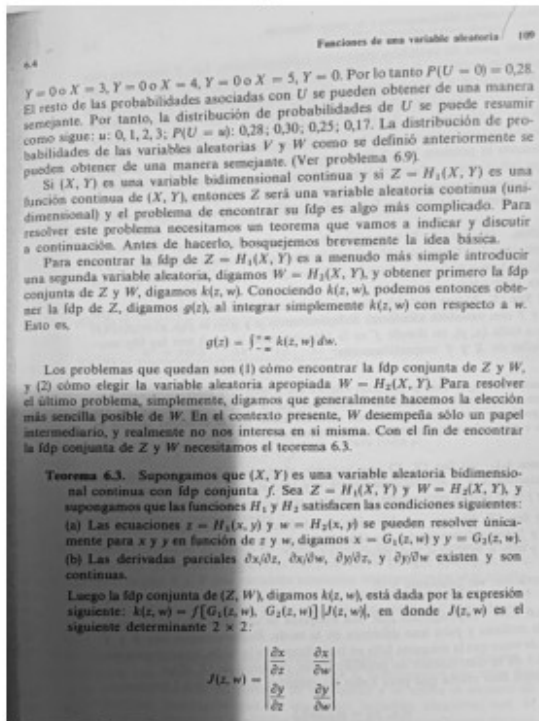
Máscara en grises



Máscara



original




Definimos la funcion de contraste que apartir de un percentil permite

```
def funcion_de_contraste(pic,percentil):
    limite = np.percentile(pic,percentil)
    blancos = pic >= limite
    pic = pic + 255*blancos
    negros_saturados = pic<limite
    blancos_saturados = pic>=limite
    pic[negros_saturados] = 0
    pic[blancos_saturados] = 255
    return pic
```

Definimos el array "Zona Oscura"

```
zona_oscura = np.full(input_pic.shape,np.nan)
limite = np.nanmean(input_pic)
for (coor_y,coor_x), value in np.ndenumerate(input_pic):
    aux = mask[coor_y:coor_y+1,coor_x:coor_x+1]
    if aux<limite: #Good Pixel
        zona_oscura[coor_y,coor_x] = input_pic[coor_y,coor_x]
    elif aux>limite: #Bad Pixel
        None
imprimir_pic(zona_oscura,"zona_oscura")
```

zona\_oscura



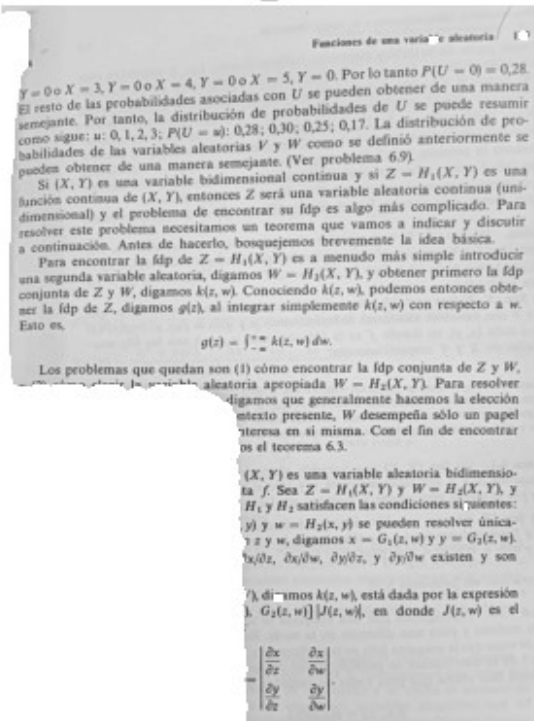
### Definimos el array "Zona Clara"

```
zona_clara = np.full(input_pic.shape,np.nan)
limite = np.nanmean(input_pic)

for (coor_y,coor_x), value in np.ndenumerate(input_pic):
    aux = mask[coor_y:coor_y+1,coor_x:coor_x+1]
    if aux>limite: #Good Pixel
        zona_clara[coor_y,coor_x] = input_pic[coor_y,coor_x]
    elif aux<=limite: #Bad Pixel
        None

imprimir_pic(zona_clara,"zona_clara")
```

## zona\_clara



Definimos la función que nos permite conocer el punto optimo para contrastar la imagen

```
def contraste_optimo_por_MSE(segmento,pic):
```

```
    output = 255 - np.nan_to_num(segmento,nan=0)
```

```
    base = 255 - pic
```

```
    errorlist = []
```

```
    for i in range(30):
```

```
        f = funcion_de_contraste(output,i)
```

```
        error = np.sum((base-f)**2)
```

```
        errorlist.append(error)
```

```
    m = np.arange(30)
```

```
    #plt.scatter( m,errorlist)
```

```
    #plt.title("Error vs intensidad (por percentile)")
```


```
    #plt.show()
```

```
    return (m[np.argmin(errorlist)]+1)
```

## METODO BASE


*Obtenemos el histograma de la zona clara con el fin de obtener su moda*

```
a,b = np.histogram(zona_clara,bins=np.arange(0,270,10))  
plt.bar( b[0:26],a[0:26],width=10)  
moda_zona_clara = b[np.argmax(a)+1]
```



*Obtenemos el histograma de la zona oscura con el fin de obtener su moda*

```
a,b = np.histogram(zona_oscura,bins=np.arange(0,270,10))  
plt.bar( b[0:26],a[0:26],width=10)  
moda_zona_oscura = b[np.argmax(a)+1]
```



*Modificamos el histograma de la zona oscura con el fin de igualar la moda de ambas zonas*

```
osc = np.copy(zona_oscura) + ( -moda_zona_oscura + moda_zona_clara)
```

```
#osc = zona_oscura
```

```
lessThen0 = osc<0
```

```
moreThen255 = osc>255
```

```
osc[lessThen0] = 0
```

```
osc[moreThen255] = 255
```

```
#imprimir_pic(osc,"osc")
```


```
a,b = np.histogram(osc,bins=np.arange(0,270,10))
```

```
plt.bar( b[0:26],a[0:26],width=10)
```

```
#moda_zona_oscura = b[np.argmax(a)+1]
```


```
<BarContainer object of 26 artists>
```





```
imprimir_pic(osc,"Zona oscura con histograma modificado")
```

Zona oscura con histograma modificado



```
imprimir_pic(zona_clara,"zona_clara")
```

zona\_clara



*Combinamos ambas zonas: la zona clara y la zona oscura modificada*

```
z1 = np.nan_to_num(zona_clara,0)
```

```
z2 = np.nan_to_num(osc,0)
```

```
suma_parcial = (z1 + z2)
```

```
imprimir_pic(suma_parcial,"combianadas")
```

## combianadas



*Restamos las mascara (en tonos de gris) de la imagen original*

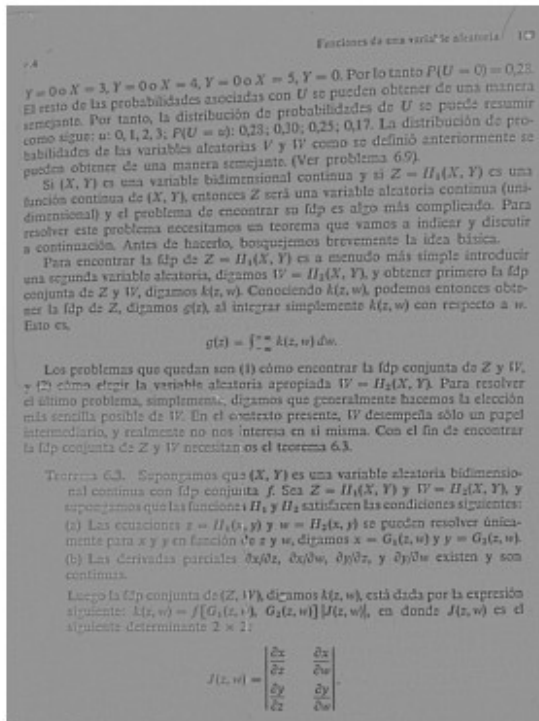
```
resta_parcial = np.copy(suma_parcial)
```

```
mask_gris = ndimage.median_filter(suma_parcial,
size=15,mode='reflect')
```

```
resta_parcial = ((suma_parcial - mask_gris)+255)/(2)
lessThen0 = resta_parcial<0
moreThen255 = resta_parcial>255
resta_parcial[lessThen0] = 0
resta_parcial[moreThen255] = 255
```

```
imprimir_pic(resta_parcial,"resta")
```

## resta



Aplicamos un contraste optimizado por MSE a la imagen de "resta parcial"

```
p_indicado = contraste_optimo_por_MSE(255 - resta_parcial, 255 -
input_pic)
final_metodo_BASE = funcion_de_contraste(resta_parcial, p_indicado)
imprimir_pic(final_metodo_BASE, "final_metodo_BASE")
```

## final\_metodo\_BASE

Funciones de una variable aleatoria 107

$Y = 0 \Leftrightarrow X = 3, Y = 0 \Leftrightarrow X = 4, Y = 0 \Leftrightarrow X = 5, Y = 0$ . Por lo tanto  $P(U = 0) = 0,28$ . El resto de las probabilidades asociadas con  $U$  se pueden obtener de una manera semejante. Por tanto, la distribución de probabilidades de  $U$  se puede resumir como sigue:  $u: 0, 1, 2, 3; P(U = u): 0,28; 0,30; 0,25; 0,17$ . La distribución de probabilidades de las variables aleatorias  $V$  y  $W$  como se definió anteriormente se pueden obtener de una manera semejante. (Ver problema 6.5).

Si  $(X, Y)$  es una variable bidimensional continua y si  $Z = H_1(X, Y)$  es una función continua de  $(X, Y)$ , entonces  $Z$  será una variable aleatoria continua (unidimensional) y el problema de encontrar su fdp es algo más complicado. Para resolver este problema necesitamos un teorema que vamos a indicar y discutir a continuación. Antes de hacerlo, bosquejemos brevemente la idea básica.

Para encontrar la fdp de  $Z = H_1(X, Y)$  es a menudo más simple introducir una segunda variable aleatoria, digamos  $W = H_2(X, Y)$ , y obtener primero la fdp conjunta de  $Z$  y  $W$ , digamos  $k(z, w)$ . Conociendo  $k(z, w)$ , podemos entonces obtener la fdp de  $Z$ , digamos  $g(z)$ , al integrar simplemente  $k(z, w)$  con respecto a  $w$ . Esto es,

$$g(z) = \int_{-\infty}^{\infty} k(z, w) dw.$$

Los problemas que quedan son (1) cómo encontrar la fdp conjunta de  $Z$  y  $W$ , y (2) cómo elegir la variable aleatoria apropiada  $W = H_2(X, Y)$ . Para resolver el último problema, simplemente, digamos que generalmente hacemos la elección más sencilla posible de  $W$ . En el contexto presente,  $W$  desempeña sólo un papel intermediario, y realmente no nos interesa en sí misma. Con el fin de encontrar la fdp conjunta de  $Z$  y  $W$  necesitamos el teorema 6.3.

**Teorema 6.3.** Supongamos que  $(X, Y)$  es una variable aleatoria bidimensional continua con fdp conjunta  $f$ . Sea  $Z = H_1(X, Y)$  y  $W = H_2(X, Y)$ , y supongamos que las funciones  $H_1$  y  $H_2$  satisfacen las condiciones siguientes:

- (a) Las ecuaciones  $x = H_1(x, y)$  y  $w = H_2(x, y)$  se pueden resolver únicamente para  $x$  y  $y$  en función de  $z$  y  $w$ , digamos  $x = G_1(z, w)$  y  $y = G_2(z, w)$ .
- (b) Las derivadas parciales  $\partial x/\partial z$ ,  $\partial x/\partial w$ ,  $\partial y/\partial z$ , y  $\partial y/\partial w$  existen y son continuas.

Luego la fdp conjunta de  $(Z, W)$ , digamos  $k(z, w)$ , está dada por la expresión siguiente:  $k(z, w) = f[G_1(z, w), G_2(z, w)] |J(z, w)|$ , en donde  $J(z, w)$  es el siguiente determinante  $2 \times 2$ :

$$J(z, w) = \begin{vmatrix} \frac{\partial x}{\partial z} & \frac{\partial x}{\partial w} \\ \frac{\partial y}{\partial z} & \frac{\partial y}{\partial w} \end{vmatrix}$$

## METODO B

# Importar las librerías necesarias:

```
import matplotlib.pyplot as plt
from PIL import Image
import scipy.ndimage as snd
import numpy as np
import cv2
from skimage.filters import threshold_otsu
from cv2 import threshold, adaptiveThreshold
```

# Declarar metodos para aplicar Clausura y Threshold:

```
def closing(image_array):
```

# Estructurar elemento de clausura:

huella = np.ones((40, 40))

# Aplicar clausura de grises:

fondo = snd.grey\_closing(image\_array, footprint=huella)

# Se resta el fondo de la imagen:

```
fondo_libre = (image_array.astype(np.float64) -
fondo.astype(np.float64))
```

# Se reescala la imagen con el fondo libre de 0 a 255:

denominador = (fondo\_libre.max() - fondo\_libre.min())

```

    fondo_libre_normalizado = (fondo_libre - fondo_libre.min())*
255/denominador
    # Convertir fondo_libre_normalizado a uint8:
    fondo_libre_normalizado = fondo_libre_normalizado.astype(np.uint8)
    # Convertir fondo_libre_normalizado a imagen:
    fondo_libre_normalizado = Image.fromarray(fondo_libre_normalizado)
    return fondo_libre_normalizado

```

```

def threshold(image_array):
    th = cv2.adaptiveThreshold(np.asarray(image_array),
        255, # Maximo valor asignado al valor de un pixel que excede el
        'threshold'.
        cv2.ADAPTIVE_THRESH_MEAN_C, # suma ponderada "gaussiana" de los
        vecinos.
        cv2.THRESH_BINARY, # Tipo de threshold.
        15, # Tamaño del bloque (ventana 5x5)
        12)

    # Convertir th a imagen:
    th = Image.fromarray(th)

    return th

```

```

# Importar imagen:
input_image = input_pic
# Convertir la imagen en arreglo:
image_array = np.asarray(input_image)
# Aplicar Clausura:
closing_image = closing(image_array)
# Aplicar Threshold:
threshold_image = threshold(closing_image)

```

```

input_image

```

```

array([[194, 194, 194, ..., 198, 198, 198],
       [194, 194, 194, ..., 198, 198, 198],
       [194, 194, 194, ..., 198, 198, 198],
       ...,
       [ 39,  40,  42, ..., 193, 193, 193],
       [ 39,  40,  42, ..., 193, 193, 193],
       [ 39,  40,  42, ..., 193, 193, 193]], dtype=uint8)

```

```

closing_image

```

6.4

$Y = 0 \circ X = 3, Y = 0 \circ X = 4, Y = 0 \circ X = 5, Y = 0$ . Por lo tanto  $P(U = 0) = 0,28$ . El resto de las probabilidades asociadas con  $U$  se pueden obtener de una manera semejante. Por tanto, la distribución de probabilidades de  $U$  se puede resumir como sigue:  $u: 0, 1, 2, 3; P(U = u): 0,28; 0,30; 0,25; 0,17$ . La distribución de probabilidades de las variables aleatorias  $V$  y  $W$  como se definió anteriormente se pueden obtener de una manera semejante. (Ver problema 6.9).

Si  $(X, Y)$  es una variable bidimensional continua y si  $Z = H_1(X, Y)$  es una función continua de  $(X, Y)$ , entonces  $Z$  será una variable aleatoria continua (unidimensional) y el problema de encontrar su fdp es algo más complicado. Para resolver este problema necesitamos un teorema que vamos a indicar y discutir a continuación. Antes de hacerlo, bosquejemos brevemente la idea básica.

Para encontrar la fdp de  $Z = H_1(X, Y)$  es a menudo más simple introducir una segunda variable aleatoria, digamos  $W = H_2(X, Y)$ , y obtener primero la fdp conjunta de  $Z$  y  $W$ , digamos  $k(z, w)$ . Conociendo  $k(z, w)$ , podemos entonces obtener la fdp de  $Z$ , digamos  $g(z)$ , al integrar simplemente  $k(z, w)$  con respecto a  $w$ . Esto es,

$$g(z) = \int_{-\infty}^{+\infty} k(z, w) dw.$$

Los problemas que quedan son (1) cómo encontrar la fdp conjunta de  $Z$  y  $W$ , y (2) cómo elegir la variable aleatoria apropiada  $W = H_2(X, Y)$ . Para resolver el último problema, simplemente, digamos que generalmente hacemos la elección más sencilla posible de  $W$ . En el contexto presente,  $W$  desempeña sólo un papel intermediario, y realmente no nos interesa en sí misma. Con el fin de encontrar la fdp conjunta de  $Z$  y  $W$  necesitamos el teorema 6.3.

**Teorema 6.3.** Supongamos que  $(X, Y)$  es una variable aleatoria bidimensional continua con fdp conjunta  $f$ . Sea  $Z = H_1(X, Y)$  y  $W = H_2(X, Y)$ , y supongamos que las funciones  $H_1$  y  $H_2$  satisfacen las condiciones siguientes:

- (a) Las ecuaciones  $z = H_1(x, y)$  y  $w = H_2(x, y)$  se pueden resolver únicamente para  $x$  y  $y$  en función de  $z$  y  $w$ , digamos  $x = G_1(z, w)$  y  $y = G_2(z, w)$ .
- (b) Las derivadas parciales  $\partial x/\partial z$ ,  $\partial x/\partial w$ ,  $\partial y/\partial z$ , y  $\partial y/\partial w$  existen y son continuas.

Luego la fdp conjunta de  $(Z, W)$ , digamos  $k(z, w)$ , está dada por la expresión siguiente:  $k(z, w) = f[G_1(z, w), G_2(z, w)] |J(z, w)|$ , en donde  $J(z, w)$  es el siguiente determinante  $2 \times 2$ :

$$J(z, w) = \begin{vmatrix} \frac{\partial x}{\partial z} & \frac{\partial x}{\partial w} \\ \frac{\partial y}{\partial z} & \frac{\partial y}{\partial w} \end{vmatrix}.$$

threshold\_image

6.4

$Y = 0 \circ X = 3, Y = 0 \circ X = 4, Y = 0 \circ X = 5, Y = 0$ . Por lo tanto  $P(U = 0) = 0,28$ . El resto de las probabilidades asociadas con  $U$  se pueden obtener de una manera semejante. Por tanto, la distribución de probabilidades de  $U$  se puede resumir como sigue:  $u: 0, 1, 2, 3; P(U = u): 0,28; 0,30; 0,25; 0,17$ . La distribución de probabilidades de las variables aleatorias  $V$  y  $W$  como se definió anteriormente se pueden obtener de una manera semejante. (Ver problema 6.9).

Si  $(X, Y)$  es una variable bidimensional continua y si  $Z = H_1(X, Y)$  es una función continua de  $(X, Y)$ , entonces  $Z$  será una variable aleatoria continua (unidimensional) y el problema de encontrar su fdp es algo más complicado. Para resolver este problema necesitamos un teorema que vamos a indicar y discutir a continuación. Antes de hacerlo, bosquejemos brevemente la idea básica.

Para encontrar la fdp de  $Z = H_1(X, Y)$  es a menudo más simple introducir una segunda variable aleatoria, digamos  $W = H_2(X, Y)$ , y obtener primero la fdp conjunta de  $Z$  y  $W$ , digamos  $k(z, w)$ . Conociendo  $k(z, w)$ , podemos entonces obtener la fdp de  $Z$ , digamos  $g(z)$ , al integrar simplemente  $k(z, w)$  con respecto a  $w$ . Esto es,

$$g(z) = \int_{-\infty}^{+\infty} k(z, w) dw.$$

Los problemas que quedan son (1) cómo encontrar la fdp conjunta de  $Z$  y  $W$ , y (2) cómo elegir la variable aleatoria apropiada  $W = H_2(X, Y)$ . Para resolver el último problema, simplemente, digamos que generalmente hacemos la elección más sencilla posible de  $W$ . En el contexto presente,  $W$  desempeña sólo un papel intermediario, y realmente no nos interesa en sí misma. Con el fin de encontrar la fdp conjunta de  $Z$  y  $W$  necesitamos el teorema 6.3.

**Teorema 6.3.** Supongamos que  $(X, Y)$  es una variable aleatoria bidimensional continua con fdp conjunta  $f$ . Sea  $Z = H_1(X, Y)$  y  $W = H_2(X, Y)$ , y supongamos que las funciones  $H_1$  y  $H_2$  satisfacen las condiciones siguientes:

- (a) Las ecuaciones  $z = H_1(x, y)$  y  $w = H_2(x, y)$  se pueden resolver únicamente para  $x$  y  $y$  en función de  $z$  y  $w$ , digamos  $x = G_1(z, w)$  y  $y = G_2(z, w)$ .
- (b) Las derivadas parciales  $\partial x/\partial z$ ,  $\partial x/\partial w$ ,  $\partial y/\partial z$ , y  $\partial y/\partial w$  existen y son continuas.

Luego la fdp conjunta de  $(Z, W)$ , digamos  $k(z, w)$ , está dada por la expresión siguiente:  $k(z, w) = f[G_1(z, w), G_2(z, w)] |J(z, w)|$ , en donde  $J(z, w)$  es el siguiente determinante  $2 \times 2$ :

$$J(z, w) = \begin{vmatrix} \frac{\partial x}{\partial z} & \frac{\partial x}{\partial w} \\ \frac{\partial y}{\partial z} & \frac{\partial y}{\partial w} \end{vmatrix}.$$

## METODO A

mask = dilation(image=mask, selem=disk(40))



```
imprimir_pic(mask, 'Máscara')  
imprimir_pic(input_pic, 'original')
```

```
/tmp/ipykernel_6417/2346952556.py:1: FutureWarning: `selem` is a  
deprecated argument name for `dilation`. It will be removed in version  
1.0. Please use `footprint` instead.
```


```
mask = dilation(image=mask, selem=disk(40))
```

Máscara

!



original




```

zona_oscura = np.full(input_pic.shape,np.nan)
limite = np.nanmean(input_pic)
for (coor_y,coor_x), value in np.ndenumerate(input_pic):
    aux = mask[coor_y:coor_y+1,coor_x:coor_x+1]
    if aux<limite: #Good Pixel
        zona_oscura[coor_y,coor_x] = input_pic[coor_y,coor_x]
    elif aux>limite: #Bad Pixel
        None
imprimir_pic(zona_oscura,"zona_oscura")

```

zona\_oscura



```
zona_clara = np.full(input_pic.shape,np.nan)
limite = np.nanmean(input_pic)

for (coor_y,coor_x), value in np.ndenumerate(input_pic):
    aux = mask[coor_y:coor_y+1,coor_x:coor_x+1]
    if aux>limite: #Good Pixel
        zona_clara[coor_y,coor_x] = input_pic[coor_y,coor_x]
    elif aux<=limite: #Bad Pixel
        None


imprimir_pic(zona_clara,"zona_clara")
```

## zona\_clara




```
#a,b = np.histogram(zona_clara,bins=np.arange(0,270,10))
#plt.bar( b[0:26],a[0:26],width=10)
#moda_zona_clara = b[np.argmax(a)+1]
#
#a,b = np.histogram(zona_oscura,bins=np.arange(0,270,10))
#plt.bar( b[0:26],a[0:26],width=10)
#moda_zona_oscura = b[np.argmax(a)+1]

osc = np.copy(zona_oscura) + ( -moda_zona_oscura + moda_zona_clara)
#osc = zona_oscura
lessThen0 = osc<0
moreThen255 = osc>255
osc[lessThen0] = 0
osc[moreThen255] = 255
#imprimir_pic(osc,"osc")
a,b = np.histogram(osc,bins=np.arange(0,270,10))
plt.bar( b[0:26],a[0:26],width=10)
#moda_zona_oscura = b[np.argmax(a)+1]
imprimir_pic(osc,"Zona oscura con histograma modificado")
imprimir_pic(zona_clara,"zona_clara")
```



Zona oscura con histograma modificado



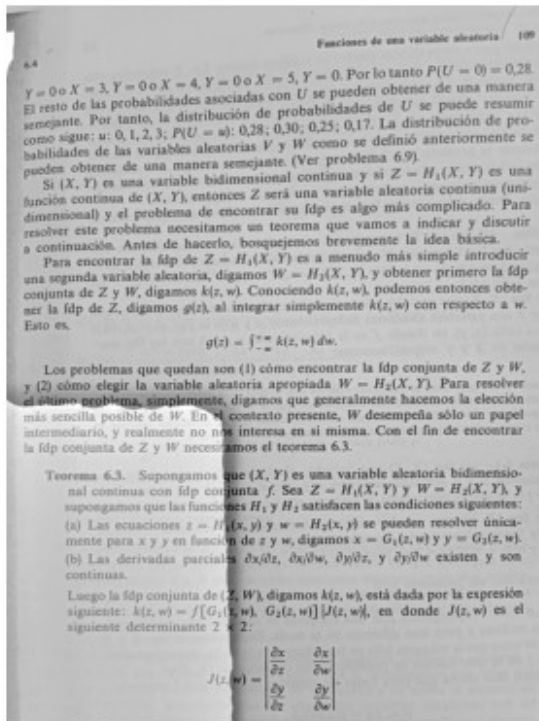
zona\_clara



```
z1 = np.nan_to_num(zona_clara,0)
z2 = np.nan_to_num(osc,0)

suma_parcial = (z1 + z2)
imprimir_pic(suma_parcial,"combianadas")
```

## combianadas



```
resta_parcial = np.copy(suma_parcial)
```

```
mask_gris = ndimage.median_filter(suma_parcial,
size=15,mode='reflect')
```

```
resta_parcial = ((suma_parcial - mask_gris)+255)/(2)
lessThen0 = resta_parcial<0
moreThen255 = resta_parcial>255
resta_parcial[lessThen0] = 0
resta_parcial[moreThen255] = 255
```

```
imprimir_pic(resta_parcial,"resta")
p_indicado = contraste_optimo_por_MSE(255 - resta_parcial,255 -
input_pic)
final_metodo_A = funcion_de_contraste(resta_parcial,p_indicado)
imprimir_pic(final_metodo_A,"final_metodo_A")
```

## resta

Funciones de una variable aleatoria 109

6.4

$Y = 0 \circ X = 3, Y = 0 \circ X = 4, Y = 0 \circ X = 5, Y = 0$ . Por lo tanto  $P(U = 0) = 0,28$ . El resto de las probabilidades asociadas con  $U$  se pueden obtener de una manera semejante. Por tanto, la distribución de probabilidades de  $U$  se puede resumir como sigue:  $u: 0, 1, 2, 3; P(U = u): 0,28; 0,30; 0,25; 0,17$ . La distribución de probabilidades de las variables aleatorias  $V$  y  $W$  como se definió anteriormente se pueden obtener de una manera semejante. (Ver problema 6.9).

Si  $(X, Y)$  es una variable bidimensional continua y si  $Z = H_1(X, Y)$  es una función continua de  $(X, Y)$ , entonces  $Z$  será una variable aleatoria continua (unidimensional) y el problema de encontrar su fdp es algo más complicado. Para resolver este problema necesitamos un teorema que vamos a indicar y discutir a continuación. Antes de hacerlo, bosquejemos brevemente la idea básica.

Para encontrar la fdp de  $Z = H_1(X, Y)$  es a menudo más simple introducir una segunda variable aleatoria, digamos  $W = H_2(X, Y)$ , y obtener primero la fdp conjunta de  $Z$  y  $W$ , digamos  $k(z, w)$ . Conociendo  $k(z, w)$ , podemos entonces obtener la fdp de  $Z$ , digamos  $g(z)$ , al integrar simplemente  $k(z, w)$  con respecto a  $w$ . Esto es,

$$g(z) = \int_{-\infty}^{\infty} k(z, w) dw.$$

Los problemas que quedan son (1) cómo encontrar la fdp conjunta de  $Z$  y  $W$ , y (2) cómo elegir la variable aleatoria apropiada  $W = H_2(X, Y)$ . Para resolver el último problema, simplemente, digamos que generalmente hacemos la elección más sencilla posible de  $W$ . En el contexto presente,  $W$  desempeña sólo un papel intermediario, y realmente no nos interesa en sí misma. Con el fin de encontrar la fdp conjunta de  $Z$  y  $W$  necesitamos el teorema 6.3.

**Teorema 6.3.** Supongamos que  $(X, Y)$  es una variable aleatoria bidimensional continua con fdp conjunta  $f$ . Sea  $Z = H_1(X, Y)$  y  $W = H_2(X, Y)$ , y supongamos que las funciones  $H_1$  y  $H_2$  satisfacen las condiciones siguientes:

- Las ecuaciones  $z = H_1(x, y)$  y  $w = H_2(x, y)$  se pueden resolver únicamente para  $x$  y  $y$  en función de  $z$  y  $w$ , digamos  $x = G_1(z, w)$  y  $y = G_2(z, w)$ .
- Las derivadas parciales  $\partial x/\partial z, \partial x/\partial w, \partial y/\partial z$ , y  $\partial y/\partial w$  existen y son continuas.

Luego la fdp conjunta de  $(Z, W)$ , digamos  $k(z, w)$ , está dada por la expresión siguiente:  $k(z, w) = f[G_1(z, w), G_2(z, w)] |J(z, w)|$ , en donde  $J(z, w)$  es el siguiente determinante  $2 \times 2$ :

$$J(z, w) = \begin{vmatrix} \frac{\partial x}{\partial z} & \frac{\partial x}{\partial w} \\ \frac{\partial y}{\partial z} & \frac{\partial y}{\partial w} \end{vmatrix}.$$

## final\_metodo\_A

Funciones de una variable aleatoria 109

6.4

$Y = 0 \circ X = 3, Y = 0 \circ X = 4, Y = 0 \circ X = 5, Y = 0$ . Por lo tanto  $P(U = 0) = 0,28$ . El resto de las probabilidades asociadas con  $U$  se pueden obtener de una manera semejante. Por tanto, la distribución de probabilidades de  $U$  se puede resumir como sigue:  $u: 0, 1, 2, 3; P(U = u): 0,28; 0,30; 0,25; 0,17$ . La distribución de probabilidades de las variables aleatorias  $V$  y  $W$  como se definió anteriormente se pueden obtener de una manera semejante. (Ver problema 6.9).

Si  $(X, Y)$  es una variable bidimensional continua y si  $Z = H_1(X, Y)$  es una función continua de  $(X, Y)$ , entonces  $Z$  será una variable aleatoria continua (unidimensional) y el problema de encontrar su fdp es algo más complicado. Para resolver este problema necesitamos un teorema que vamos a indicar y discutir a continuación. Antes de hacerlo, bosquejemos brevemente la idea básica.

Para encontrar la fdp de  $Z = H_1(X, Y)$  es a menudo más simple introducir una segunda variable aleatoria, digamos  $W = H_2(X, Y)$ , y obtener primero la fdp conjunta de  $Z$  y  $W$ , digamos  $k(z, w)$ . Conociendo  $k(z, w)$ , podemos entonces obtener la fdp de  $Z$ , digamos  $g(z)$ , al integrar simplemente  $k(z, w)$  con respecto a  $w$ . Esto es,

$$g(z) = \int_{-\infty}^{\infty} k(z, w) dw.$$

Los problemas que quedan son (1) cómo encontrar la fdp conjunta de  $Z$  y  $W$ , y (2) cómo elegir la variable aleatoria apropiada  $W = H_2(X, Y)$ . Para resolver el último problema, simplemente, digamos que generalmente hacemos la elección más sencilla posible de  $W$ . En el contexto presente,  $W$  desempeña sólo un papel intermediario, y realmente no nos interesa en sí misma. Con el fin de encontrar la fdp conjunta de  $Z$  y  $W$  necesitamos el teorema 6.3.

**Teorema 6.3.** Supongamos que  $(X, Y)$  es una variable aleatoria bidimensional continua con fdp conjunta  $f$ . Sea  $Z = H_1(X, Y)$  y  $W = H_2(X, Y)$ , y supongamos que las funciones  $H_1$  y  $H_2$  satisfacen las condiciones siguientes:

- Las ecuaciones  $z = H_1(x, y)$  y  $w = H_2(x, y)$  se pueden resolver únicamente para  $x$  y  $y$  en función de  $z$  y  $w$ , digamos  $x = G_1(z, w)$  y  $y = G_2(z, w)$ .
- Las derivadas parciales  $\partial x/\partial z, \partial x/\partial w, \partial y/\partial z$ , y  $\partial y/\partial w$  existen y son continuas.

Luego la fdp conjunta de  $(Z, W)$ , digamos  $k(z, w)$ , está dada por la expresión siguiente:  $k(z, w) = f[G_1(z, w), G_2(z, w)] |J(z, w)|$ , en donde  $J(z, w)$  es el siguiente determinante  $2 \times 2$ :

$$J(z, w) = \begin{vmatrix} \frac{\partial x}{\partial z} & \frac{\partial x}{\partial w} \\ \frac{\partial y}{\partial z} & \frac{\partial y}{\partial w} \end{vmatrix}.$$

```
plt.figure(figsize=(15,12))
plt.subplot(1,4, 1)
```

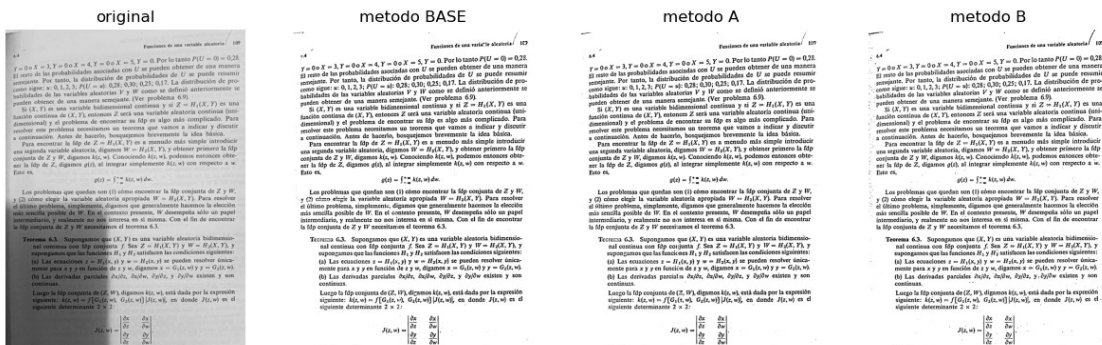


```
plt.imshow(input_pic, cmap = 'gray')
plt.title('original')
plt.axis('off')

plt.subplot(1,4, 2)
plt.imshow(final_metodo_BASE, cmap = 'gray')
plt.axis('off')
plt.title('metodo BASE')
```

```
plt.subplot(1,4, 3)
plt.imshow(final_metodo_A, cmap = 'gray')
plt.axis('off')
plt.title('metodo A')
```

```
plt.subplot(1,4, 4)
plt.imshow(threshold_image, cmap = 'gray')
plt.axis('off')
plt.title('metodo B')
plt.show()
```



Guardamos el mejor resultado como archivo jpeg  
 type(threshold\_image)

PIL.Image.Image

nombre = imagen\_entrada + "\_PROCESADA.jpeg"

threshold\_image.save(nombre)